

Домашняя работа биоинформатика номер 1

Шилина Виктория

Анализ выполнен в QIIME 2 версии 2024.10. Окружение через conda создать не удалось - канал `packages.qiime2.org` с кластера отдаёт только 16 КБ из 93 КБ файла `repodata.json` и обрывает соединение, поэтому использовался официальный контейнер с `quay.io`, запущенный через Singularity.

Задание 1:

1. Выберем образец SRR17307380 (самый маленький по числу прочтений)

```
sample-id      absolute-filepath
SRR17307316    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307316_1.fastq
SRR17307649    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307649_1.fastq
SRR17307364    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307364_1.fastq
SRR17307666    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307666_1.fastq
SRR17307610    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307610_1.fastq
SRR17307475    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307475_1.fastq
SRR17307392    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307392_1.fastq
SRR17307419    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307419_1.fastq
SRR17307492    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307492_1.fastq
SRR17307436    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307436_1.fastq
SRR17307380    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307380_1.fastq
SRR17307593    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307593_1.fastq
SRR17307269    /home/STUDY/FBMF/bioinformatics/metagenomes/soil_hw/raw_reads/SRR17307269_1.fastq
```

2. Запустим на нём FastQC, импортируем все образцы в формат QIIME2


Demultiplexed sequence counts summary

	forward reads
Minimum	5128
Median	15852.0
Mean	17815.611111
Maximum	45492
Total	641362


Forward Reads Frequency Histogram

Reverse Reads Frequency Histogram

No reads in this direction



Качество сырых данных:




These plots were generated using a random sampling of 10000 out of 641362 sequences without replacement. The minimum sequence length identified during subsampling was 251 bases. Outlier quality scores are not shown in box plots for clarity.

Parametric seven-number summary		
Box plot feature	Percentile	Quality score
(Not shown in box plot)	2nd	...
Lower Whisker	9th	...
Bottom of Box	25th	...
Middle of Box	50th (Median)	...
Top of Box	75th	...
Upper Whisker	91st	...
(Not shown in box plot)	98th	...

✓ Basic Statistics

Measure	Value
Filename	SRR17307380_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	5128
Total Bases	1.2 Mbp
Sequences flagged as poor quality	0
Sequence length	251
%GC	57


✓ Per base sequence quality



Качество высокое и держится ровно почти до конца рида, снижение начинается ближе к 3'-концу - обычная для Illumina картина. Адаптеров нет. Медианное качество держится в зелёной зоне на всей длине рида, но около 180 позиции нижние кватили и усы уходят в жёлтую и

красную зоны. Часть прочтений к концу заметно хуже. Это и обосновывает выбор `--p-trunc-len 200`: обрезаем ровно там, где начинается разброс.

Красные крестики на Per base sequence content, Overrepresented sequences и Sequence Duplication Levels появляются, так как это ампликонные данные, все риды покрывают один и тот же участок 16S rRNA, поэтому дубликация зашкаливает по определению, а перекося в первых позициях - это праймер. FastQC рассчитан на полногеномные библиотеки со случайными фрагментами.



Скрипт для SLURM:

```
#!/bin/sh
#SBATCH --job-name=qiime2_dada
#SBATCH --cpus-per-task=16
#SBATCH --mem=32gb
#SBATCH --time=06:00:00
#SBATCH --output=JobName.%j.log

qiime dada2 denoise-single \
  --i-demultiplexed-seqs qza/soil_reads.qza \
  --p-trim-left 25 \           # длина праймера 515F 19 нт + запас
  --p-trunc-len 200 \         # качество к концу ридов хуже
  --p-max-ee 3 \
  --p-n-threads 16 \
  --p-pooling-method "pseudo" \
  --p-chimera-method "consensus" \
  --p-min-fold-parent-over-abundance 4 \
  --o-table qza/soil_ASV_table.qza \
  --o-representative-sequences qza/soil_rep_seq.qza \
  --o-denoising-stats qza/soil_reads.dada2.stats.qza
```

Задание 2:

Зачем мы используем параметр `--p-trim-left 25`?

Чтобы отрезать праймер 515F. Он занимает первые 19 нуклеотидов и информации о бактерии не несёт, а вот навредить может: в праймере есть вырожденная позиция (M = A/C), и прочитанный там нуклеотид определяется праймером, а не геномом. DADA2 воспримет такие различия как биологический сигнал и разделит один организм на несколько разных ASV. Плюс начало ридов обычно менее качественное.

Задание 3:

Какая примерно доля исходных прочтений остаётся после всех стадий фильтрации?


sample-id	input	filtered	percentage of input passed filter	denoised	non-chimeric	percentage of input non-chimeric
#2-types	numeric	numeric	numeric	numeric	numeric	numeric
SRR17307258	26992	26932	99.78	26472	25395	94.08
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307269	10387	10322	99.37	9859	9859	94.92
SRR17307273	23451	23405	99.8	23023	20966	89.4
SRR17307278	24834	24783	99.79	24230	23607	95.06
SRR17307316	10833	10723	98.98	10193	10189	94.06
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307392	25424	25374	99.8	24617	24547	96.55
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307406	22460	22420	99.82	21987	21190	94.35
SRR17307409	29485	29434	99.83	28819	28088	95.26
SRR17307413	9875	9740	98.63	9595	9532	96.53
SRR17307419	24624	24574	99.8	23982	23904	97.08
SRR17307420	9962	9873	99.11	9453	9441	94.77
SRR17307436	9471	9380	99.04	9019	8993	94.95
SRR17307475	45492	45407	99.81	44292	43518	95.66

Фильтр по качеству проходит 98,3-99,8%, до конца доживает 89,4-97,1%. То есть основные потери происходят на удалении химер, а сама фильтрация по качеству почти ничего не отрезает.

Сколько прочтений осталось в самом большом и в самом маленьком образцах?

Frequency per sample

	Frequency
Minimum frequency	4 809
1st quartile	8 974.2
Median frequency	14 908
3rd quartile	24 708.8
Maximum frequency	43 518
Mean frequency	16 898.9



Download as PDF

non-chimeric	non-chimeric
numeric	numeric
4809	43518
4866	29356
5731	29346
6634	28088
7291	27473
7705	26936

43 518 и 4 809 (SRR17307380), медиана 14 908. Разброс почти в десять раз. Разные образцы, разная глубина секвенирования.

Что полученные результаты говорят о качестве данных?

Прочтения качественные, больше 89% доходит до финальной таблицы, параметры обрезки подобраны нормально. Но глубина между образцами очень неровная, поэтому перед оценкой разнообразия нужно разрежение до общей глубины (взяли 4809, по самому маленькому).

Задание 4:

Изначально праймеры были подобраны для амплификации V4-V5 регионов, почему нам достаточно использовать классификатор, обученный только на V4 регионе?


Потому что мы работаем только с прямыми ридами. Ампликон V4-V5 около 400 нт, но рид всего 250, а после обрезки (trim-left 25, trunc-len 200) от него остаётся 175 нт. Этот кусок начинается сразу за праймером 515F и целиком укладывается внутрь V4. Поэтому классификатор, обученный на V4, полностью соответствует данным.



sample-id	contamination_level	replica_number	day_after_contamination	level_and_time_point
#q2:types	categorical	categorical	categorical	categorical
SRR17307316	k0	r1	d3	k0_t1
SRR17307649	k0	r2	d3	k0_t1
SRR17307364	k0	r3	d3	k0_t1

Задание 5:


Посмотрите распределение классов бактерий (Level 3), удобно упорядочить график по переменной level_and_time_point. Опишите полученные результаты. Похожи ли образцы в первой временной точке? Как меняется состав сообществ со временем? Какие самые частые классы в первой и в последней временной точках? Увеличьте таксономическое разрешение до уровня бактериального рода (Level 6). Какой самый частый род в загрязнённых образцах? Ожидаемо ли увидеть его при загрязнении керосином?



В первой точке (d3) образцы всех трёх уровней загрязнения выглядят практически одинаково - сообщество ещё не успело отреагировать. Профиль обычный для дерново-подзолистого почвы: доминируют Acidobacteriae и Alphaproteobacteria, а дальше много классов примерно сопоставимыми долями, то есть сообщество богатое и равномерное.

Контроль k0 таким и остаётся все четыре точки. А в загрязнённых доля Gammaproteobacteria растёт от точки к точке и в поздних доходит до 30–90%, вытесняя всех остальных. Причём эффект развивается не сразу, так как бактериям нужно время, чтобы нарастить биомассу на новом источнике углерода.

Самые частые классы: в первой точке везде Acidobacteriae и Alphaproteobacteria, в последней - Gammaproteobacteria в загрязнённых и по-прежнему Acidobacteriae в контроле.




На уровне рода это оказывается

d__Bacteria;p__Proteobacteria;c__Gammaproteobacteria;o__Burkholderiales_592524;f__Burkholderiaceae_A_580492;g__Paraburkholderia_580243.


Увидеть его при загрязнении керосином вполне ожидаемо: буркхольдерии умеют разлагать углеводороды, в том числе алканы и ароматику. Для них керосин не ядовит, а съедобен, поэтому загрязнение даёт им преимущество перед остальной олиготрофной почвенной микробиотой.

Перед переходом к бета-разнообразию построим дерево:




Задание 6:

Опишите наблюдаемые результаты. Похожи ли образцы в первой временной точке? Как меняется их положение со временем? Есть ли признаки восстановления сообщества после слабого или сильного загрязнения со временем?



Все образцы в t1 сгруппированы близко, что подтверждает исходную однородность сообщества. Дальше группы расходятся вдоль первой оси (56,2% вариации). Контроль смещается компактно, t2, t3 и t4 стоят рядом. Загрязнённые уезжают в противоположную сторону, и тем дальше, чем больше прошло времени: k25_t2 в центре, k25_t3 левее, k25_t4 в самом краю. Слабое загрязнение даёт ту же траекторию, но мягче - точки k5 остаются ближе к контролю, чем соответствующие точки k25. Возвращения к исходному состоянию не видно ни при k5, ни при k25.

Загрязнение керосином оказывается главным фактором: на первую ось приходится 56,2% вариации, то есть больше, чем на все остальные вместе.




Интересно сравнить с невзвешенным UniFrac: там первая ось объясняет всего 35,3%, и экстремальное положение k25_t4 исчезает, расстояния между группами становятся сопоставимыми. Значит, керосин не столько выбивает таксон, сколько перекашивает их обилие, большая часть исходного сообщества сохраняется, просто в малых количествах, задавленная *Paraburkholderia*. То есть потенциал для восстановления есть, просто за 360 дней он не реализовался.


Задание 7:

Опишите как меняется разнообразие бактериального сообщества со временем при разном уровне загрязнения образцов.

Alpha Diversity Boxplots



Alpha Diversity Boxplots



Контроль k0: разнообразие стабильно высокое (медиана около 8,8) и почти не меняется во времени, разброс между репликами минимальный.

Слабое загрязнение k5: промежуточные значения, медиана около 7,3.

Сильное загрязнение k25: самая низкая медиана, около 7,0, но размах от 2,6 до 9,0. Такой разброс это и есть временная динамика внутри группы.


По времени эффект накапливается, а не срабатывает сразу. В первой точке все три уровня около 9,0, различий нет. Дальше разнообразие падает монотонно, и тем быстрее, чем выше доза. При k5 индекс опускается до 6,7 и выходит на плато, при k25 падение только ускоряется, к последней точке остаётся 3,0, то есть треть от исходного. За время наблюдения ни в одной группе разнообразие не восстанавливается.

Разброс между репликами внутри точки везде минимальный, кроме k25_t3, там сообщества расходятся сильнее всего, похоже на момент перестройки.


Данные mice (то, что делали на семинаре)

29 образцов кишечной микробиоты из статьи Rosshart et al., Cell 2017. Четыре группы: L - лабораторные мыши, W - дикие, LR и WR - germ-free мыши, колонизированные лабораторной и дикой микробиотой.

Параметры DADA2 подбирали по графику качества: --p-trunc-len-f 240 и --p-trunc-len-r 200. Ампликон V4 около 291 нт, значит перекрытие остаётся порядка 150 нт - с запасом. До конца доживает 58-73% прочтений. Разрежение до 2000 (из 29 образцов остаётся 27).



По таксономии у L и LR доминируют Clostridia (70-80%), а у W их доля падает до 25–60%, зато поднимаются Campylobacter, Desulfobacteria и Gammaproteobacteria. WR наследует именно дикий профиль. Названия таксонов не совпадают с теми, что в статье, потому что GreenGenes2 использует таксономию GTDB: Firmicutes там разделены на Firmicutes_A/B/D, а часть бывших Proteobacteria вынесена в Campylobacterota и Desulfobacterota.



PERMANOVA: pseudo-F = 19,40, $p = 0,001$. Все попарные сравнения значимы, но величина различий разная: L vs LR всего 5,3 (перенос лабораторной микробиоты воспроизводит донора почти точно), W vs WR - 10,6, а любая пара “дикое против лабораторного” - от 21,9 до 29,5.

Overview

PERMANOVA results	
method name	PERMANOVA
test statistic name	pseudo-F
sample size	27
number of groups	4
test statistic	19.397813
p-value	0.001
number of permutations	999

PERMDISP даёт $F = 12,48$, $p = 0,001$ — дисперсии по группам неоднородны, так что часть значимости PERMANOVA может идти от разного разброса, а не только от сдвига центроидов. Но на PCoA группы всё-таки разнесены пространственно, а не просто отличаются шириной облака.

Overview

PERMDISP results	
method name	PERMDISP
test statistic name	F-value
sample size	27
number of groups	4
test statistic	12.476597
p-value	0.001
number of permutations	999

Alpha Diversity Boxplots



[Download raw data as TSV](#)

По альфа-разнообразию у диких мышей индекс Шеннона самый низкий (около 4,7) при огромном разбросе, а самый высокий у LR и WR (около 5,7). Внутри одной дикой мыши сообщество беднее, зато между разными дикими мышами различий много.

OTU или ASV

У нас везде ASV: DADA2 не задаёт порога сходства вообще, он строит по данным модель ошибок секвенирования и решает, можно ли объяснить редкую последовательность ошибками прочтения более частой. Если нельзя это отдельный реальный вариант.

В статье Rosshart et al. использованы OTU: риды сшивали в USEARCH v7, кластеризовали алгоритмом UPARSE по порогу 97%, таксономию определяли картированием на SILVA v128, урезанную до V4.

При этом авторы сами перепроверили свои данные subOTU-алгоритмом Callahan et al. 2016 (это и есть DADA2) и получили, что выводы OTU-анализа подтверждаются. Так что наш подход методически ближе к их дополнительному анализу, и расхождений в выводах ожидать не приходится. Отличаются ещё базы: SILVA 128 у них против GreenGenes2 2022.10 у нас, отсюда разница в названиях таксонов, особенно на уровне рода.