Отчёт по семинару 1. Метагеномика: данные mice

Шилина Виктория

Качество сырых данных

FastQC по 58 файлам, сводка через MultiQC.

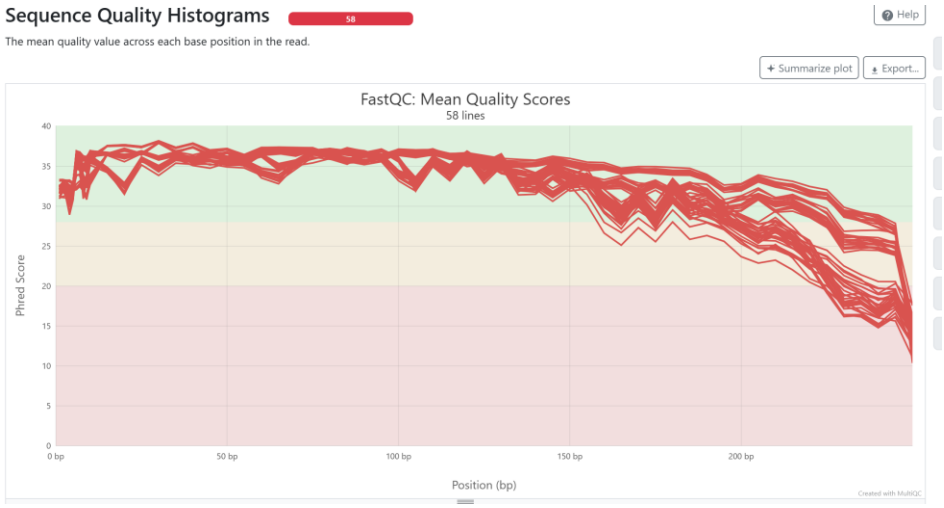

MultiQC: Mean Quality Scores по всем файлам

Качество около 35-37 примерно до 140 позиции, дальше кривые расходятся на два пучка: прямые прочтения доходят до конца на 28-30, обратные после 180 уходят в жёлтую зону и к 250 падают до 15-20.

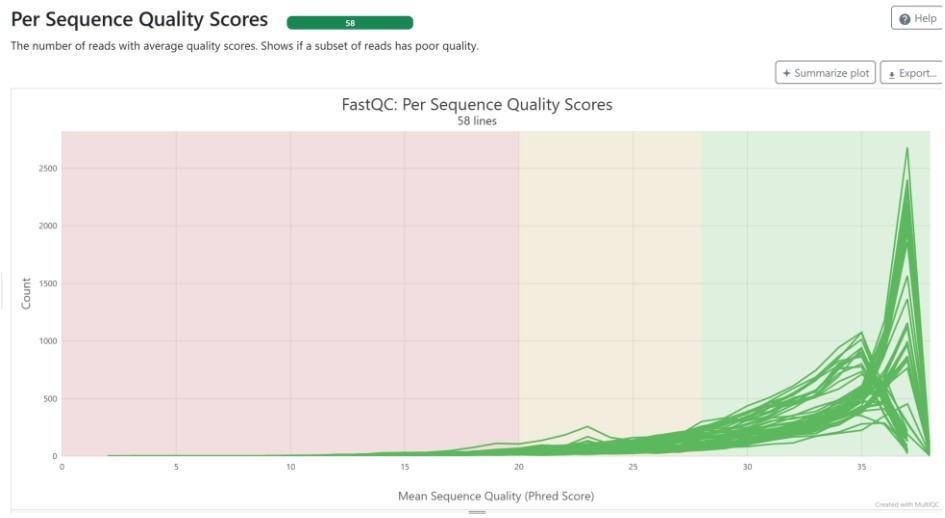

MultiQC: Per Sequence Quality Scores

Зелёный по всем файлам - субпопуляции плохих прочтений нет. Дупликация 76-90% и красный Per base sequence content ожидаемы для ампликонов: все риды покрывают один участок 16S, перекос в начале даёт праймер. GC стабильно 52-54%.

Импорт и статистика сырых прочтений

```
qiime tools import \
  --type 'SampleData[PairedEndSequencesWithQuality]' \
  --input-path $MICE/metadata_for_input.tsv \
  --output-path qza/mice_reads.qza \
  --input-format PairedEndFastqManifestPhred33V2

qiime demux summarize --i-data qza/mice_reads.qza \
  --o-visualization qzv/mice_reads.qzv
```

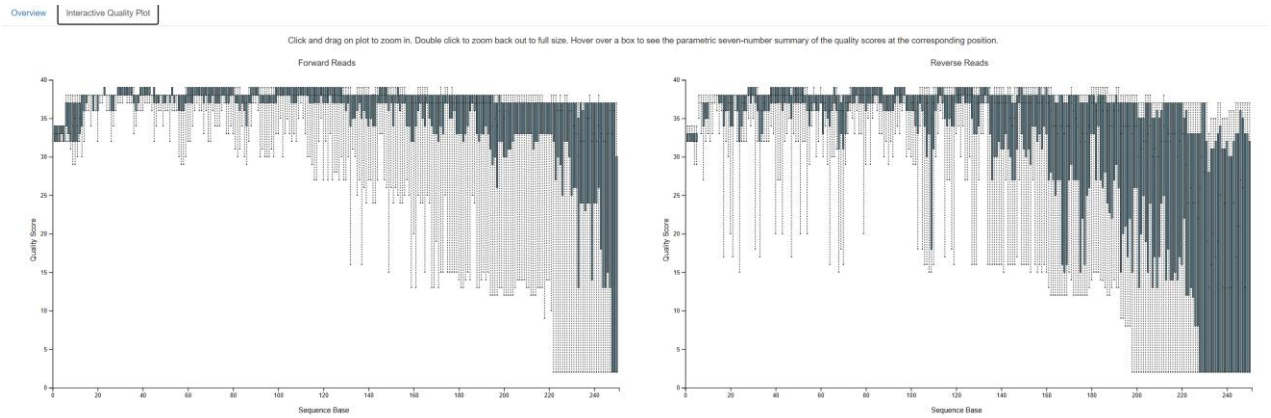

Per-sample sequence counts

Total Samples: 29 (forward) 29 (reverse)

sample ID	forward sequence count	reverse sequence count
L1	3773	3773
L2	3669	3669
L3	5346	5346
L4	3836	3836
L5	3311	3311
L6	4572	4572
L7	4536	4536
L8	3498	3498
LR1	5047	5047
LR2	6394	6394
LR3	5753	5753
LR4	6062	6062
LR5	6056	6056
LR6	5855	5855
LR7	5191	5191
W1	2138	2138
W2	3714	3714
W3	3211	3211
W4	3619	3619
W5	4301	4301
W6	5016	5016
W7	3501	3501
WR1	4804	4804
WR2	4918	4918
WR3	5446	5446
WR4	5206	5206
WR5	5450	5450
WR6	5414	5414
WR7	5035	5035

Длина прочтений по demux summarize ровно 250 нт во всех перцентилях. Forward до 200 позиции держит медиану 36-38, к 240 она опускается до 32 при нижнем квартиле 24. Reverse сыпется раньше: на 200 позиции медиана уже 30, нижний квартиль 13, а к 240 медиана падает до 13 и четверть прочтений оказывается на уровне 2. --p-trunc-len-f 240 и --p-trunc-len-r 200. Нижний ус на этих графиках - 9-й перцентиль, а не минимум: у forward он опускается до 2 уже на 240 позиции, у reverse - на 200.

DADA2

```
qiime dada2 denoise-paired \
  --i-demultiplexed-seqs qza/mice_reads.qza \
  --p-trim-left-f 19 \        # праймер 515F
  --p-trim-left-r 20 \        # праймер 806R
```

```
  --p-trunc-len-f 240 \
  --p-trunc-len-r 200 \
  --p-n-threads 16 \
  --o-table qza/mice_ASV_table.qza \
  --o-representative-sequences qza/mice_rep_seq.qza \
  --o-denoising-stats qza/mice_reads.dada2.stats.qza
```

trim-left отрезает праймеры: в них есть вырожденные позиции (M в 515F, H, V и W в 806R), и прочитанный там нуклеотид определяется праймером, а не геномом - DADA2 принял бы это за биологический сигнал и разделил один организм на разные ASV.

Sequence Length Statistics

Download sequence-length statistics as a TSV

Sequence Count	Min Length	Max Length	Mean Length	Range	Standard Deviation
517	221	221	221.0	0	0.0

Прямое прочтение после обрезки покрывает 221 нт, обратное - 180 нт, минимальное перекрытие для слияния 12 нт. По tabulate-seqs все 517 представительных последовательностей вышли длиной ровно 221 нт при нулевом стандартном отклонении, то есть длина слитой последовательности совпадает с длиной прямого прочтения. Значит обратное прочтение целиком укладывается внутри прямого и перекрытие равно всей его длине, 180 нт - с большим запасом относительно 12.

Sequence Length Statistics

Download sequence-length statistics as a TSV

Sequence Count	Min Length	Max Length	Mean Length	Range	Standard Deviation
517	221	221	221.0	0	0.0

File: mice_dada2_stats.qzv × Visualization Citations Provenance Metadata

Download metadata TSV file

This file won't necessarily reflect dynamic sorting or filtering options based on the interactive table below.

Search:

sample-id (#q2:types)	input (numeric)	filtered (numeric)	percentage of input passed filter (numeric)	denoised (numeric)	merged (numeric)	percentage of input merged (numeric)	non-chimeric (numeric)	percentage of input non-chimeric (numeric)
L1	3773	2821	74.77	2670	2533	67.13	2515	66.66
L2	3669	2744	74.79	2585	2374	64.7	2374	64.7
L3	5346	4087	76.45	3881	3517	65.79	3340	62.48
L4	3836	2733	71.25	2579	2264	59.02	2264	59.02
L5	3311	2356	71.16	2202	2007	60.62	1973	59.59
L6	4572	3298	72.13	3157	2902	63.47	2862	62.6
L7	4536	3311	72.99	3132	2894	63.8	2894	63.8
L8	3498	2445	69.9	2308	2147	61.38	2147	61.38
LR1	5047	4239	83.99	4076	3754	74.38	3754	74.38
LR2	6394	5281	82.59	5122	4681	73.21	4681	73.21
LR3	5753	4631	80.5	4459	4026	69.98	4026	69.98
LR4	6062	4864	80.24	4700	4397	72.53	4371	72.1
LR5	6056	4888	80.71	4740	4480	73.98	4480	73.98
LR6	5855	4658	79.56	4528	4092	69.89	4092	69.89
LR7	5191	4253	81.93	4082	3789	72.99	3789	72.99
W1	2138	1521	71.14	1415	1294	60.52	1257	58.79
W2	3714	2526	68.01	2359	2191	58.99	2127	57.27
W3	3211	2539	79.07	2398	2235	69.6	2115	65.87
W4	3619	2666	73.67	2492	2224	61.45	2185	60.38
W5	4301	3086	71.75	2871	2560	59.52	2477	57.59
W6	5016	3270	65.19	3047	2715	54.13	2668	53.19
W7	3501	2436	69.58	2298	2198	62.78	2062	58.9
WR1	4804	3826	79.64	3646	3399	70.75	3399	70.75
WR2	4918	3792	77.1	3600	3386	68.85	3386	68.85

Фильтр по качеству проходит 65-84%, до финальной таблицы остаётся 53,2-74,4% (минимум W6, максимум LR1), медиана около 65,9%. По группам видна систематика: у LR стабильно 70-74%, у W только 53-66%. У диких мышей теряется больше - больше редких вариантов и больше химер.

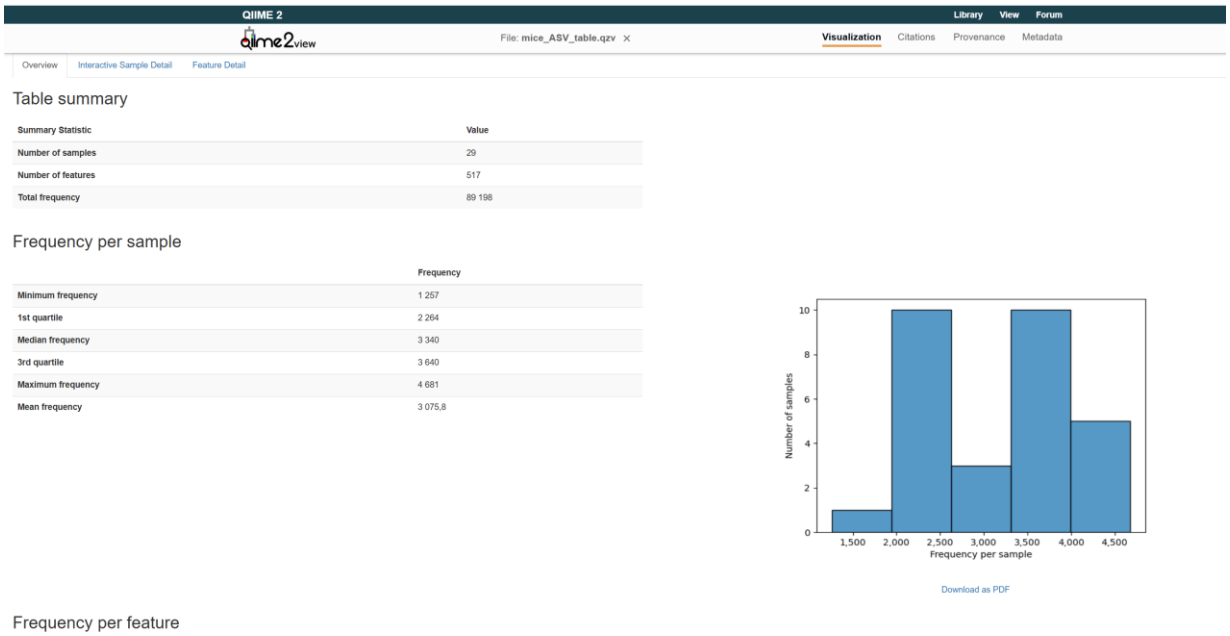

29 образцов, 517 ASV, суммарно 89 198 прочтений. Глубина от 1257 (W1) до 4681 (LR2), медиана 3340.

Таксономия

```
qiime feature-classifier classify-sklearn \
  --i-classifier $MICE/2022.10.backbone.v4.nb.sklearn-1.4.2.qza \
  --i-reads qza/mice_rep_seq.qza \
  --o-classification qza/mice_taxonomy.qza --p-n-jobs 16
```

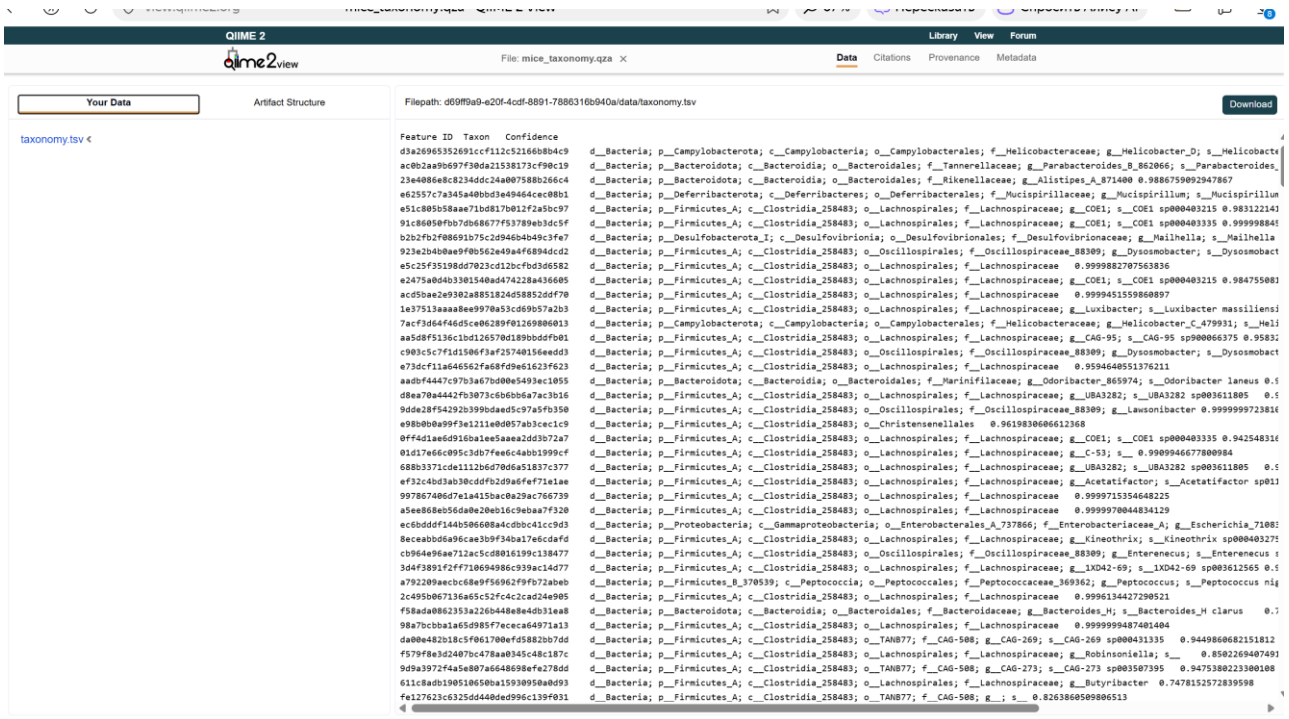

Классификатор GreenGenes2 2022.10, обученный на V4. Confidence в основном 0,94-0,99; часть ASV обрывается на семействе Lachnospiraceae - классификатор уверен в семействе, но не выбирает род.

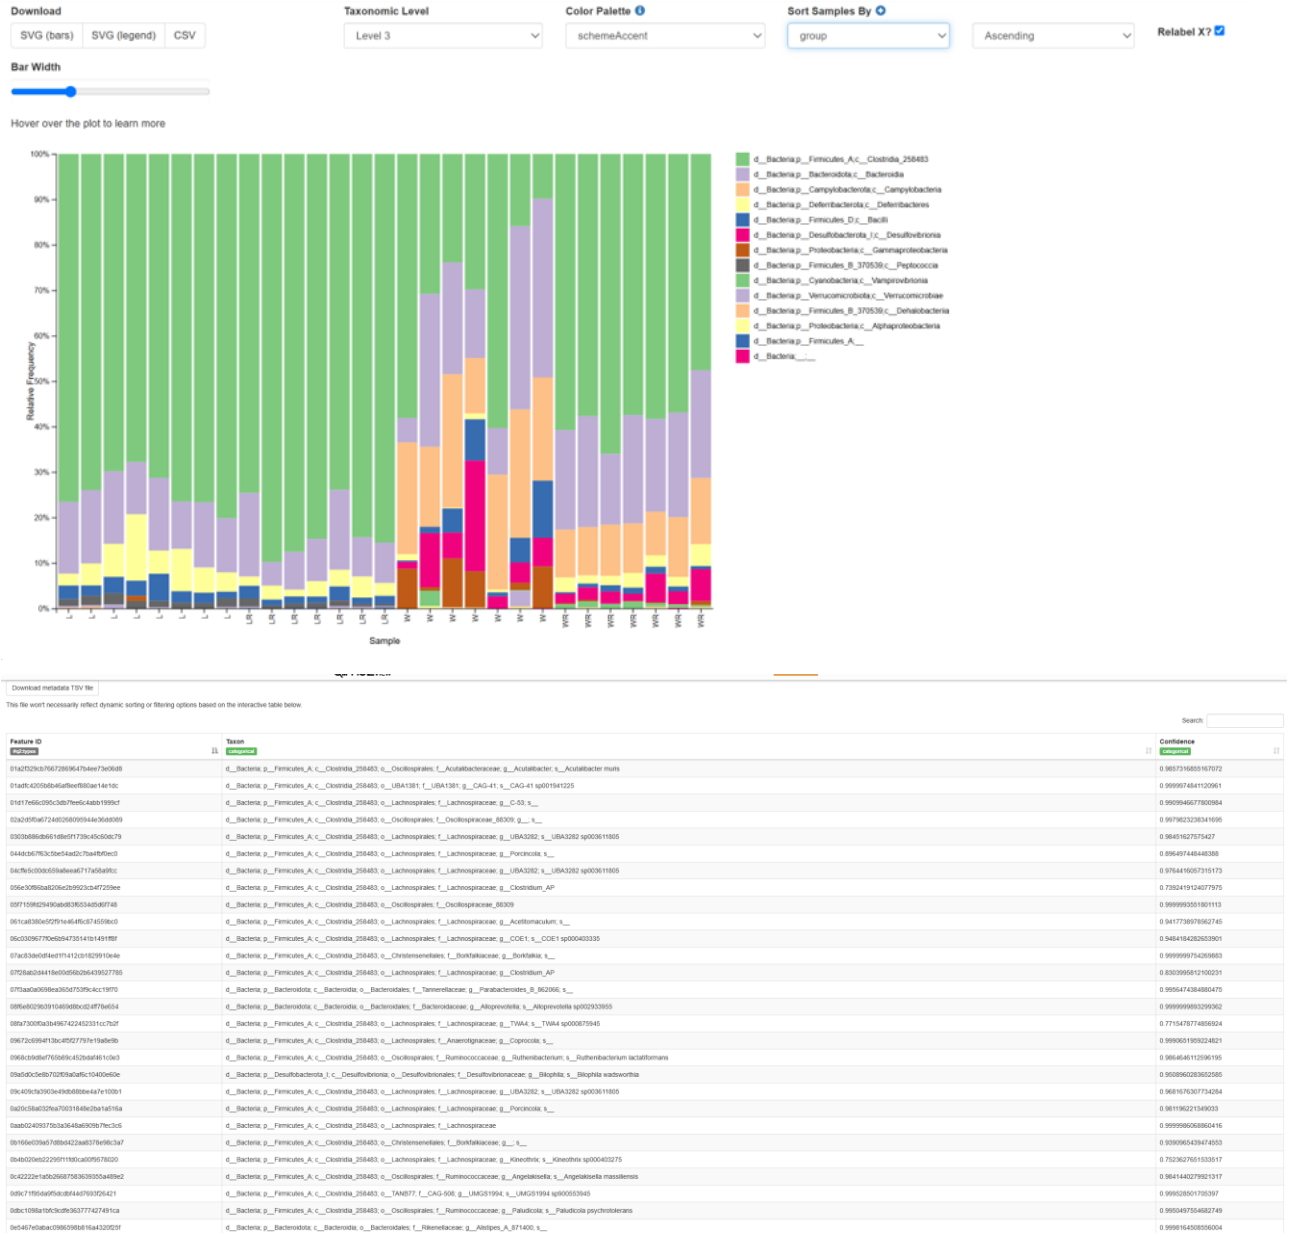

У L доминируют Clostridia: медиана 75,8% (68,3-79,7), у LR ещё выше - 85,2% (73,9-89,6). У W доля падает до 29,8% при огромном разбросе между особями, от 10,1 до 60,4%, зато поднимаются Campylobacteria, Desulfovibrionia и Gammaproteobacteria. WR наследует набор таксонов дикого профиля, но не пропорции: Clostridia там держится на 57,1% (46,6-66,8).

Названия не совпадают со статьёй: GreenGenes2 использует GTDB, где Firmicutes разделены на Firmicutes_A/B/D, а часть бывших Proteobacteria вынесена в Campylobacterota и Desulfobacterota.

Филогенетическое дерево

```
Команда не работала (плагина нет в базовом дистрибутиве amplicon): qiime empress tree-plot \
  --i-tree <path-to-qza-dir>/mice_rooted_tree.qza \
  --m-feature-metadata-file <path-to-qza-dir>/mice_taxonomy.qza \
  --o-visualization <path-to-qzv-dir>/mice_tree.qzv


Выполнено: qiime phylogeny align-to-tree-mafft-fasttree \
  --i-sequences qza/mice_rep_seq.qza \
  --o-alignment qza/aligned_mice_rep_seq.qza \
  --o-masked-alignment qza/masked_aligned_mice_rep_seq.qza \
  --o-tree qza/mice_unrooted_tree.qza \
```

```
  --o-rooted-tree qza/mice_rooted_tree.qza
```

Дерево нужно для UniFrac и Faith PD.

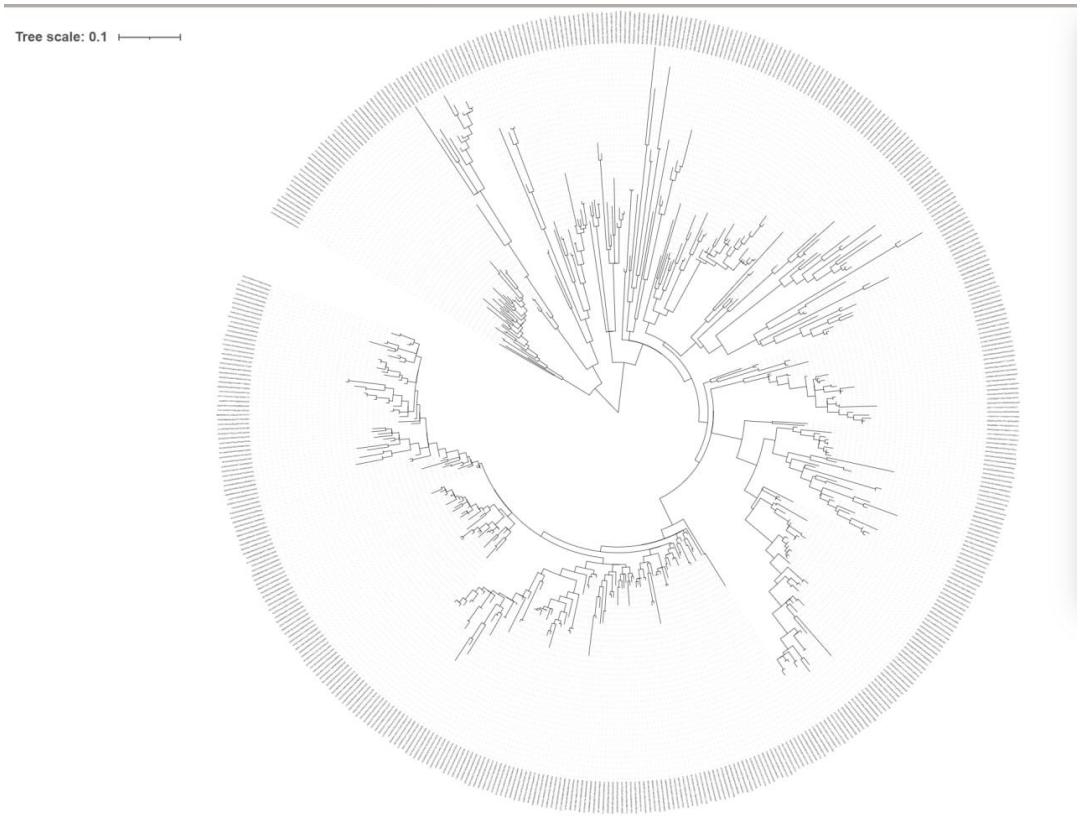

Альфа-разнообразие

```
qiime diversity core-metrics-phylogenetic \
  --i-phylogeny qza/mice_rooted_tree.qza \
  --i-table qza/mice_ASV_table.qza \
  --p-sampling-depth 2000 \
  --m-metadata-file $MICE/metadata.tsv \
  --output-dir mice_core_metrics_results
```

Порог разрежения 2000 - значение из семинара. Выпадают L5 (1973) и W1 (1257), остаётся 27: L = 7, LR = 7, W = 6, WR = 7.

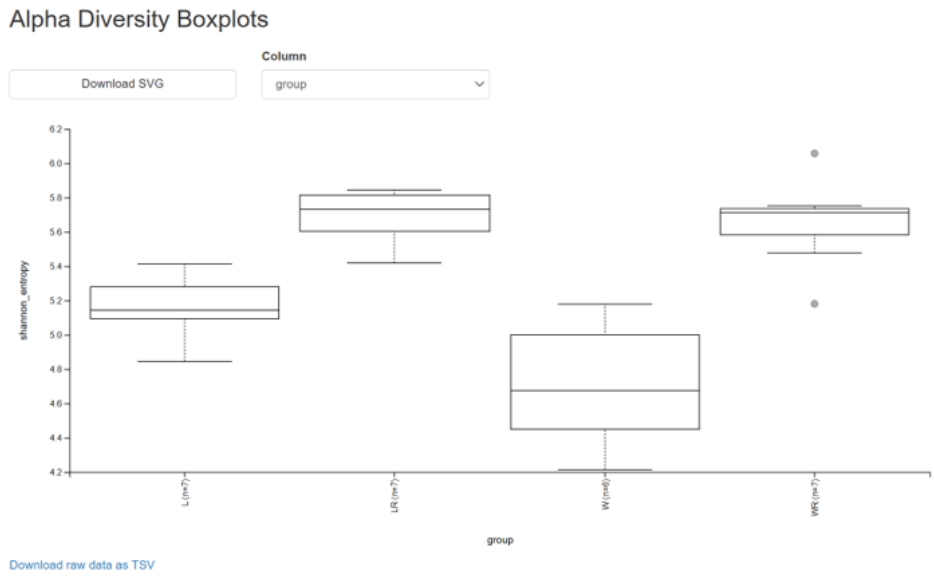

У диких мышей индекс Шеннона самый низкий, медиана 4,77, и бокс самый широкий (4,26-5,21). У L промежуточное значение 5,19, самые высокие у LR и WR - 5,82 и 5,75, то есть колонизация germ-free мышей даёт разнообразие выше, чем у обоих доноров. Крускал-Уоллис по всем группам: H = 17,78, p = 0,0005; попарно L vs LR H = 9,02, q = 0,008, а LR vs WR неразличимы (q = 0,65).

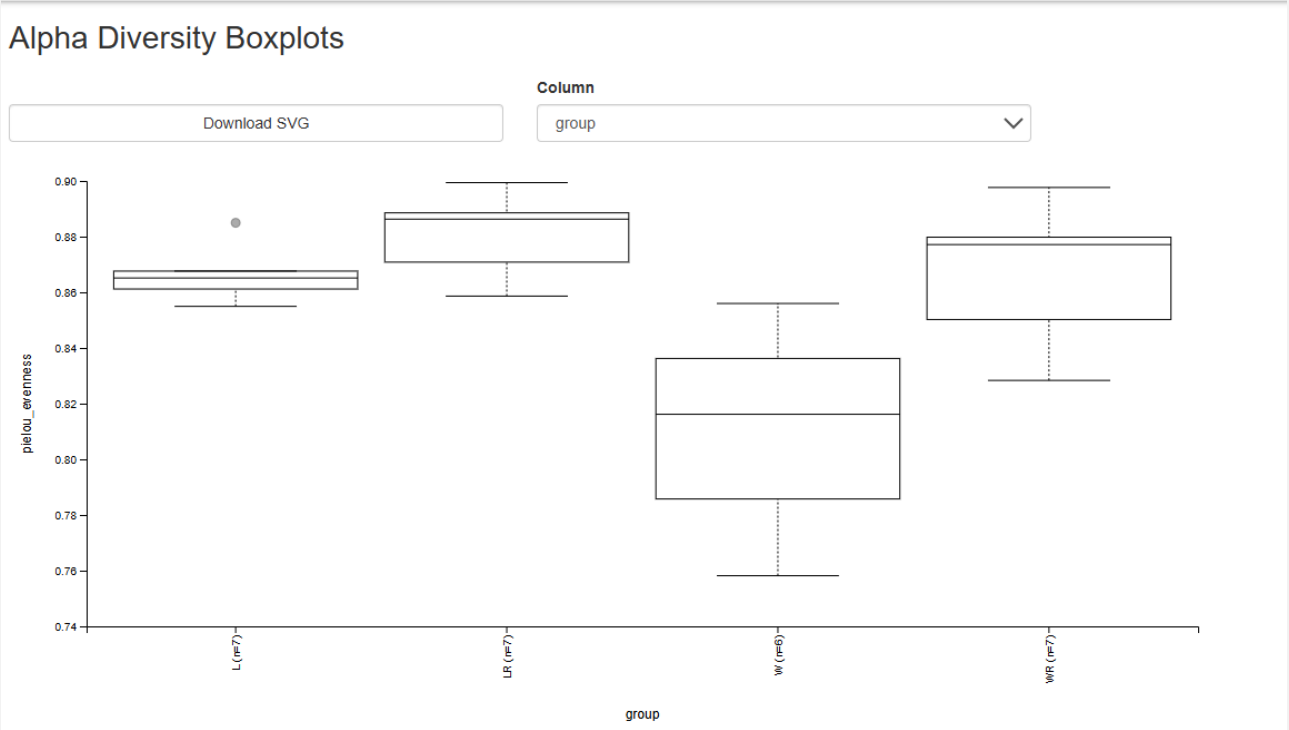

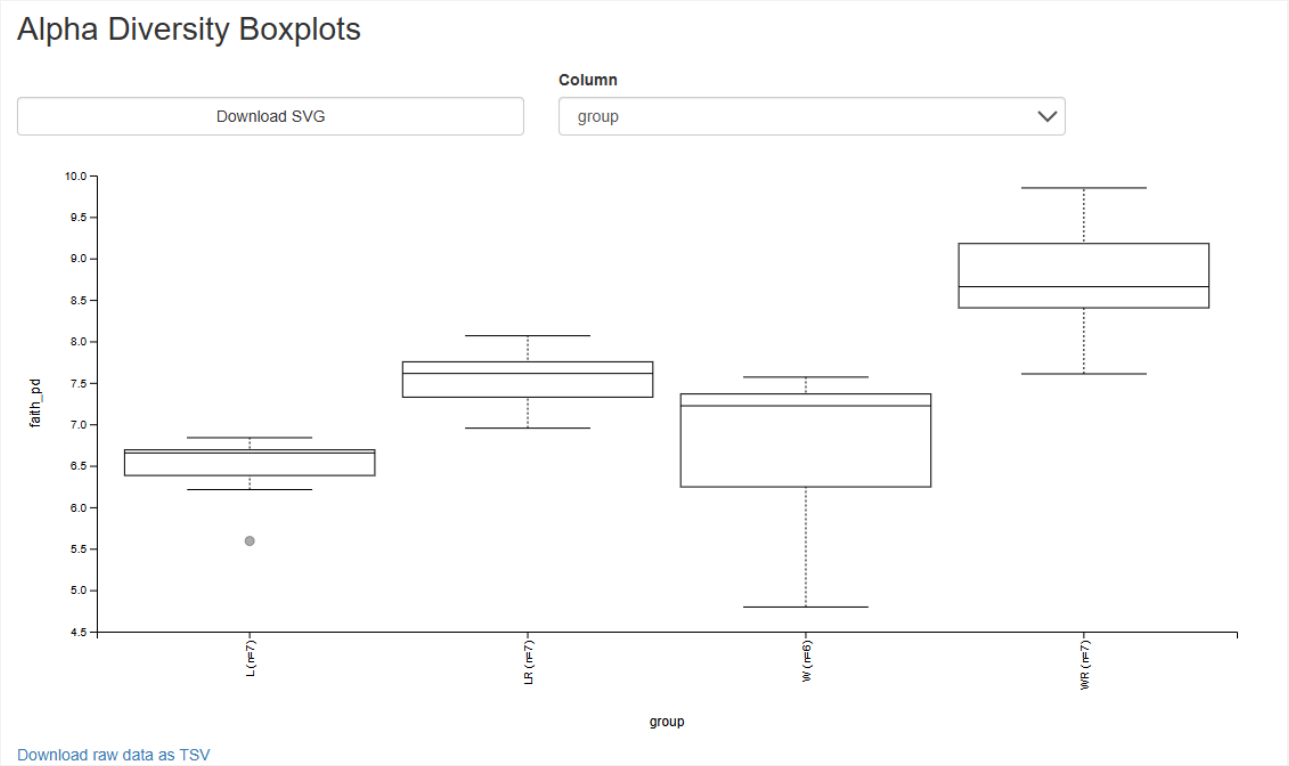

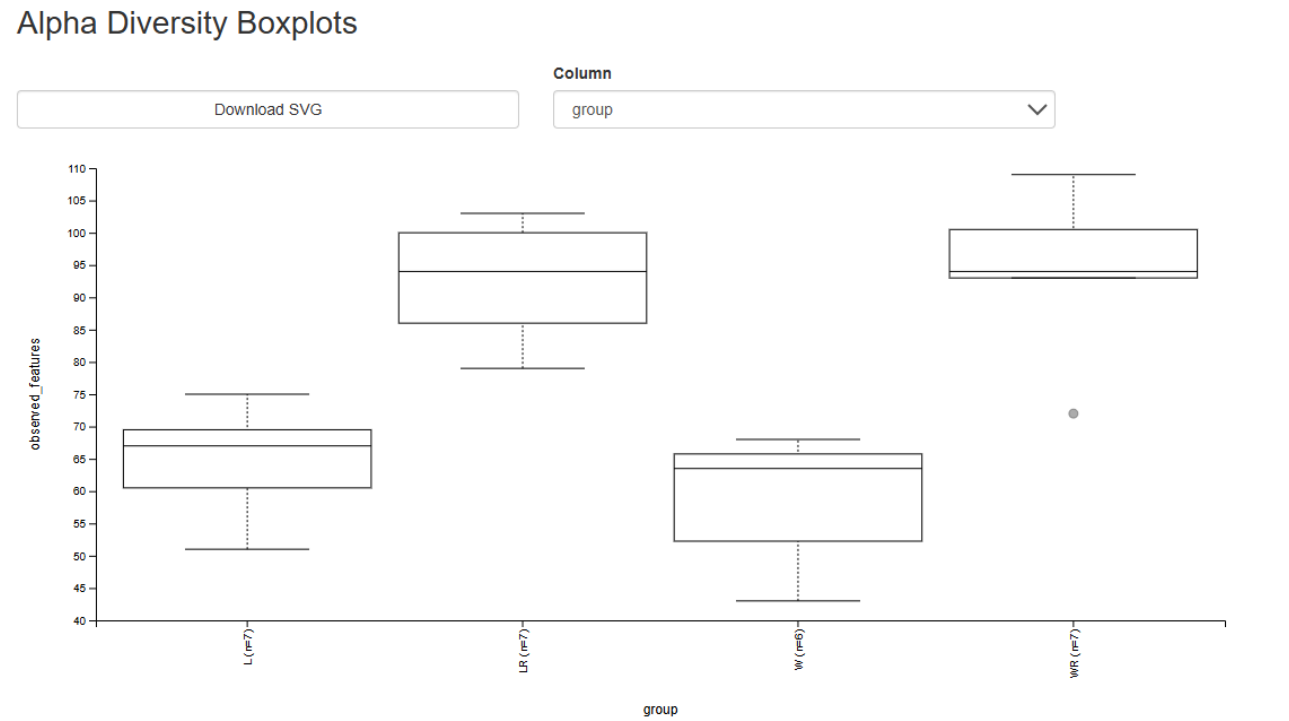

Три дополнительные метрики показывают, за счёт чего у W низкий индекс Шеннона: observed features - число ASV, равномерность Пиелу - насколько ровно распределены обилия, Faith PD - филогенетическая широта.

Число ASV у W (медиана 64) от лабораторных мышей не отличается (67 у L, q = 0,27), Faith PD тоже сопоставимы (7,22 против 6,65, q = 0,25). Значимо ниже только равномерность: 0,816 против 0,865 (q = 0,013). Линий у диких мышей столько же, и филогенетически сообщество не уже, обилие перекошено в пользу нескольких доминантов, отсюда и низкий Шеннон. У колонизированных групп картина другая: LR и WR несут больше ASV, чем их доноры (94 против 67 и 94 против 64, q = 0,004), а у WR ещё и самый высокий Faith PD - 8,66.

Бета-разнообразие

```
qiime diversity beta-group-significance \
  --i-distance-matrix .../weighted_unifrac_distance_matrix.qza \
  --m-metadata-file $MICE/metadata.tsv --m-metadata-column group \
  --p-method permanova --p-pairwise \
  --o-visualization qzv/mice_weighted_unifrac_permanova.qzv
```

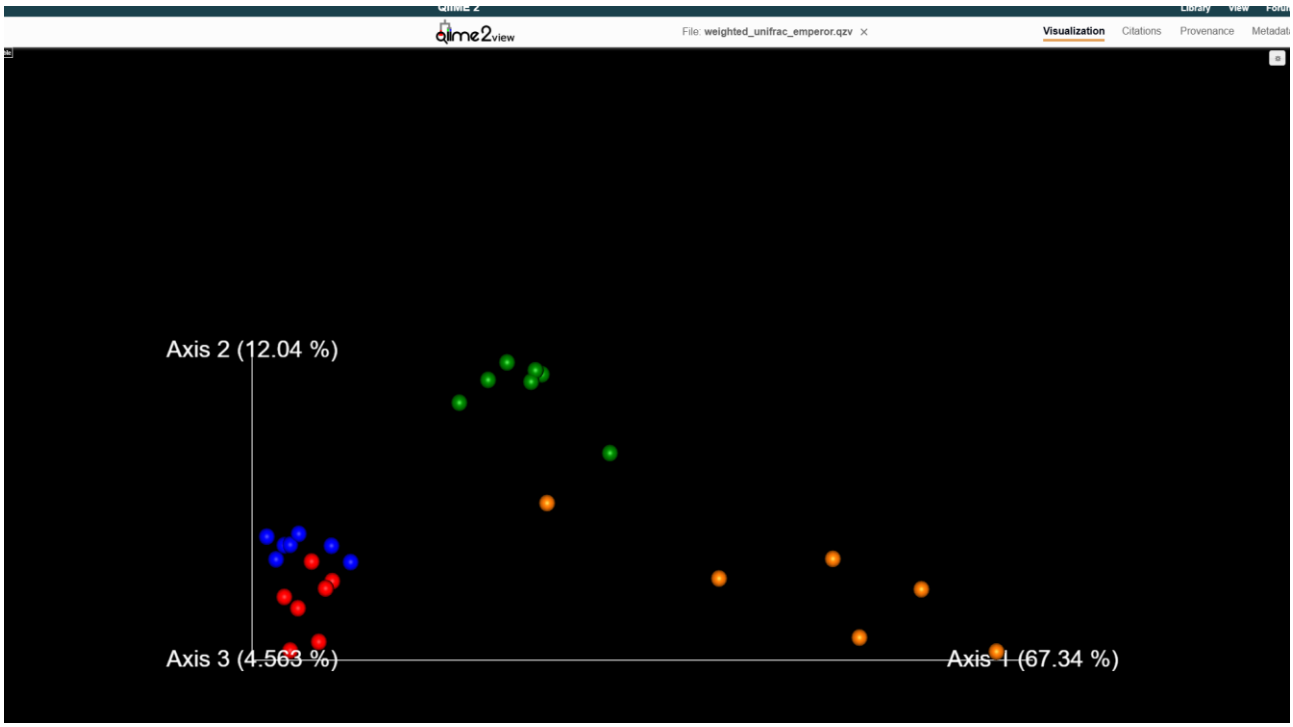

Pairwise permanova results

Download CSV

Group 1	Group 2	Sample size	Permutations	pseudo-F	p-value	q-value
L	LR	14	999	6.056405	0.001	0.0015
	W	13	999	26.908952	0.001	0.0015
	WR	14	999	29.869905	0.003	0.0030
LR	W	13	999	27.124220	0.001	0.0015
	WR	14	999	24.759070	0.001	0.0015
W	WR	13	999	12.162013	0.003	0.0030

Overview

	PERMANOVA results
method name	PERMANOVA
test statistic name	pseudo-F
sample size	27
number of groups	4
test statistic	21.675099
p-value	0.001
number of permutations	999

PERMANOVA по weighted UniFrac: pseudo-F = 21,68, p = 0,001 (27 образцов, 4 группы, 999 перестановок). Все попарные сравнения значимы, но величина различий разная: L vs LR всего 6,01 - перенос лабораторной микробиоты в germ-free воспроизводит донора почти точно, на PCoA эти группы лежат одним облаком. W vs WR - 12,16, ровно вдвое больше: дикая микробиота приживается хуже. Любая пара «дикое против лабораторного» - от 24,8 до 29,9.

Первая ось забирает 67,34% и разделяет дикий и лабораторный профили, вторая (12,04%) отделяет WR от остальных. WR оказывается не копией дикого сообщества, а третьим состоянием: набор таксонов дикий, пропорции свои.

Overview

	PERMDISP results
method name	PERMDISP
test statistic name	F-value
sample size	27
number of groups	4
test statistic	8.198082
p-value	0.002
number of permutations	999

PERMDISP по weighted UniFrac: F = 8,20, p = 0,002. Дисперсии по группам неоднородны, так что часть значимости PERMANOVA может идти от разного разброса, а не только от сдвига центроидов. Но на PCoA группы разнесены пространственно, а не отличаются шириной облака.

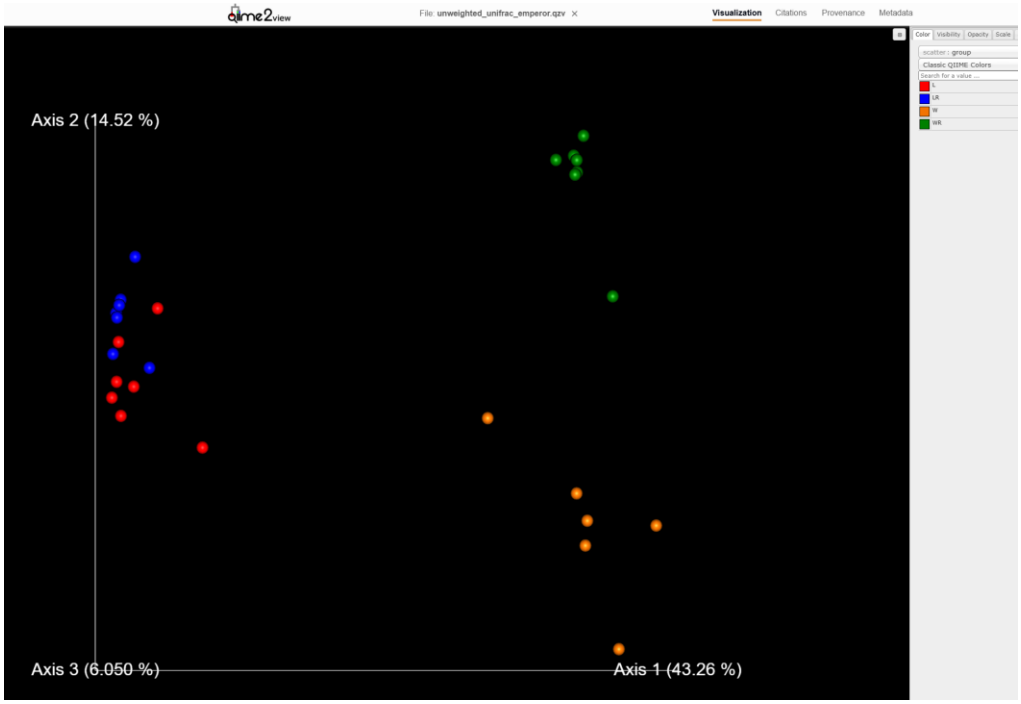

	PERMANOVA results
method name	PERMANOVA
test statistic name	pseudo-F
sample size	27
number of groups	4
test statistic	11.241078
p-value	0.001
number of permutations	999

Weighted UniFrac учитывает обилие, unweighted - только присутствие, поэтому сравнение двух метрик показывает природу различий. Unweighted: pseudo-F = 11,24, p = 0,001, первая ось 43,26%, вторая 14,52%; PERMDISP F = 9,42, p = 0,006.

	PERMDISP results
method name	PERMDISP
test statistic name	F-value
sample size	27
number of groups	4
test statistic	9.420417
p-value	0.006
number of permutations	999

По unweighted все пары остаются значимыми, но pseudo-F везде ниже: L vs LR 3,15 против 6,01, W vs WR 5,73 против 12,16, «дикое против лабораторного» 10,5-19,5 против 24,8-29,9. Меньше и доля дисперсии на первой оси: 43,26% против 67,34%. Расстановка групп при этом та же - PC1 отделяет L и LR от W и WR, а WR лежит отдельно от W по второй оси. Значит донор и реципиент различаются и по набору линий, и по их обилиям, но по обилиям заметно сильнее: состав переносится, пропорции - нет.

OTU или ASV

У нас везде ASV: DADA2 не задаёт порога сходства, он строит по данным модель ошибок секвенирования и решает, можно ли объяснить редкую последовательность ошибками прочтения более частой. Если нельзя, то это отдельный реальный вариант.

В статье использованы OTU: парные прочтения объединяли в USEARCH v7.0.1090, кластеризовали алгоритмом UPARSE по порогу сходства 97%, а таксономию определяли картированием OTU с идентичностью 97% на оптимизированную версию SILVA 128, содержащую только область V4.

При этом авторы сами перепроверили данные алгоритмом subOTU (Callahan et al., 2016), который лежит в основе DADA2, и получили, что основные выводы OTU-анализа подтверждаются. Так что наш подход методически ближе к их дополнительному анализу, и принципиальных расхождений не ожидается. Отличаются базы: SILVA 128 против GreenGenes2 2022.10, отсюда разница в названиях таксонов, особенно на уровне рода.