

Домашняя работа ChipSeq

Шилина Виктория

Тем же workflow, что на семинаре для 14ss (BAM QC → ChIP/Input BigWig → $\log_2(\text{ChIP}/\text{Input})$ → MACS3 peaks → p/q-value → FRiP → heatmap + average profile), самостоятельно проанализированы две оставшиеся стадии - 75 % эпиболии (75ep) и 1–2 сомита (1-2ss), - после чего все четыре стадии сравниваются между собой. Данные: bioChIP-seq Foxd3 у *Danio rerio*, сборка GRCz11. Стадия 5–6ss взята готовой (от преподавателя).

Стадия 75 % эпиболии (75ep)

QC: ChIP 23 863 894 выравниваний, Input 39 931 858, все корректно спарены, без дубликатов. Пиков ($q < 0,01$): 36; FRiP 0,017 %; самый значимый пик $-\log_{10}(q) = 100,05$.

Статистика ChIP BAM

```
samtools flagstat data/75ep/foxd3_75ep_chip.nuclear.bam
samtools flagstat data/75ep/foxd3_75ep_input.nuclear.bam
```

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@calc chipseq_seminar]$ samtools flagstat data/75ep/foxd3_75ep_chip.nuclear.ba
23863894 + 0 in total (QC-passed reads + QC-failed reads)
23863894 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
23863894 + 0 mapped (100.00% : N/A)
23863894 + 0 primary mapped (100.00% : N/A)
23863894 + 0 paired in sequencing
11931947 + 0 read1
11931947 + 0 read2
23863894 + 0 properly paired (100.00% : N/A)
23863894 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@calc chipseq_seminar]$ samtools flagstat data/75ep/foxd3_75ep_input.nu
39931858 + 0 in total (QC-passed reads + QC-failed reads)
39931858 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
39931858 + 0 mapped (100.00% : N/A)
39931858 + 0 primary mapped (100.00% : N/A)
39931858 + 0 paired in sequencing
19965929 + 0 read1
19965929 + 0 read2
39931858 + 0 properly paired (100.00% : N/A)
39931858 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

Сигнал и пики

```
bamCoverage -b data/75ep/foxd3_75ep_chip.nuclear.bam -o results/signal/foxd3_75ep_chip.CPM.bw --
normalizeUsing CPM --binSize 10 -p 4
bamCoverage -b data/75ep/foxd3_75ep_input.nuclear.bam -o results/signal/foxd3_75ep_input.CPM.bw --
normalizeUsing CPM --binSize 10 -p 4
bigwigCompare -b1 results/signal/foxd3_75ep_chip.CPM.bw -b2 results/signal/foxd3_75ep_input.CPM.bw --
operation log2 --pseudocount 1 --binSize 10 -o results/signal/foxd3_75ep.log2_IP_Input.bw
macs3 callpeak -t data/75ep/foxd3_75ep_chip.nuclear.bam -c data/75ep/foxd3_75ep_input.nuclear.bam -f BAMPE -
g 1360000000 -n foxd3_75ep -q 0.01 --outdir results/peaks
wc -l results/peaks/foxd3_75ep_peaks.narrowPeak
sort -k9,9nr results/peaks/foxd3_75ep_peaks.narrowPeak | head
```

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@ca
36 results/peaks/foxd3_75ep_peaks.narrowPeak
```


```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@ca chipseq_seminar]$ sort -k9,9nr results/peaks/foxd3_75ep
NC_007113.7 33276014 33276551 foxd3_75ep_peak_2 1000 . 21.7013 109.261 100.05 250
NC_007115.7 24985705 24986018 foxd3_75ep_peak_7 913 . 17.5995 98.7489 91.316 121
NC_007117.7 32206595 32206920 foxd3_75ep_peak_10 590 . 6.56514 65.8648 59.0704 161
NC_007113.7 55663601 55663948 foxd3_75ep_peak_3 537 . 11.611 60.4356 53.7724 137
NC_007127.7 7514954 7515335 foxd3_75ep_peak_23 469 . 11.2879 53.4818 46.9143 151
NC_007115.7 17823395 17823709 foxd3_75ep_peak_6 316 . 8.60073 37.8856 31.6151 163
NC_007114.7 14914294 14914628 foxd3_75ep_peak_4 306 . 13.8159 36.9118 30.6693 163
NC_007131.7 9427912 9428181 foxd3_75ep_peak_28 287 . 10.2493 34.8713 28.7145 158
NC_007128.7 29024873 29025199 foxd3_75ep_peak_25 275 . 7.3427 33.6443 27.5164 159
NC_007123.7 43641492 43641809 foxd3_75ep_peak_18 215 . 6.08544 27.5885 21.5723 152
```


FRiP

```
samtools view -c data/75ep/foxd3_75ep_chip.nuclear.bam
samtools view -c -L results/peaks/foxd3_75ep_peaks.narrowPeak data/75ep/foxd3_75ep_chip.nuclear.bam
```

```
reads всего: 23863894 | в пиках: 4101 | FRiP: 0.00017
```

Метапрофиль и heatmap





Стадия 1–2 сомита (1-2ss)

QC: ChIP 12 816 614 выравниваний, Input 33 460 348, все корректно спарены, без дубликатов. Пиков ($q < 0,01$): 40; FRIp 0,014 %; самый значимый пик $-\log_{10}(q) = 56,18$.

Статистика ChIP BAM

```
samtools flagstat data/1-2ss/foxd3_1-2ss_chip.nuclear.bam
samtools flagstat data/1-2ss/foxd3_1-2ss_input.nuclear.bam
```

```
/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq [studfbmf01_29@calc chipseq_seminar]$ samtools flagstat data/1-2ss/foxd3_1-2ss_chip.nuclear.bam
12816614 + 0 in total (QC-passed reads + QC-failed reads)
12816614 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
12816614 + 0 mapped (100.00% : N/A)
12816614 + 0 primary mapped (100.00% : N/A)
12816614 + 0 paired in sequencing
6408307 + 0 read1
6408307 + 0 read2
12816614 + 0 properly paired (100.00% : N/A)
12816614 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

```
/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq [studfbmf01_29@calc chipseq_seminar]$ samtools flagstat data/1-2ss/foxd3_1-2ss_input.nuclear.bam
33460348 + 0 in total (QC-passed reads + QC-failed reads)
33460348 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
33460348 + 0 mapped (100.00% : N/A)
33460348 + 0 primary mapped (100.00% : N/A)
33460348 + 0 paired in sequencing
16730174 + 0 read1
16730174 + 0 read2
33460348 + 0 properly paired (100.00% : N/A)
33460348 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

Сигнал и пики

```
bamCoverage -b data/1-2ss/foxd3_1-2ss_chip.nuclear.bam -o results/signal/foxd3_1-2ss_chip.CPM.bw --
normalizeUsing CPM --binSize 10 -p 4
bamCoverage -b data/1-2ss/foxd3_1-2ss_input.nuclear.bam -o results/signal/foxd3_1-2ss_input.CPM.bw --
normalizeUsing CPM --binSize 10 -p 4
bigwigCompare -b1 results/signal/foxd3_1-2ss_chip.CPM.bw -b2 results/signal/foxd3_1-2ss_input.CPM.bw --
operation log2 --pseudocount 1 --binSize 10 -o results/signal/foxd3_1-2ss.log2_IP_Input.bw
macs3 callpeak -t data/1-2ss/foxd3_1-2ss_chip.nuclear.bam -c data/1-2ss/foxd3_1-2ss_input.nuclear.bam -f
BAMPE -g 136000000 -n foxd3_1-2ss -q 0.01 --outdir results/peaks
wc -l results/peaks/foxd3_1-2ss_peaks.narrowPeak
sort -k9,9nr results/peaks/foxd3_1-2ss_peaks.narrowPeak | head
```

```

40 results/peaks/foxd3_1-2ss_peaks.narrowPeak
NC_007113.7 33276062 33276596 foxd3_1-2ss_peak_3 561 . 21.2286 65.2724 56.183 217
NC_007127.7 7514971 7515391 foxd3_1-2ss_peak_26 431 . 18.3517 50.1931 43.1796 197
NC_007117.7 32206548 32206898 foxd3_1-2ss_peak_11 306 . 8.41677 37.2941 30.6517 216
NC_007115.7 24985734 24985998 foxd3_1-2ss_peak_6 196 . 11.0145 26.0538 19.6907 105
NC_007132.7 43198481 43198771 foxd3_1-2ss_peak_31 163 . 8.88315 22.6804 16.3879 116
NC_007129.7 44276036 44276277 foxd3_1-2ss_peak_28 153 . 9.80542 21.6301 15.3616 110
NC_007135.7 4487327 4487612 foxd3_1-2ss_peak_36 150 . 9.01274 21.3055 15.0579 147
NC_007134.7 29069326 29069544 foxd3_1-2ss_peak_34 145 . 8.70767 20.7384 14.5072 91
NC_007123.7 43641530 43641795 foxd3_1-2ss_peak_22 142 . 8.31004 20.5018 14.2791 92
NC_007116.7 824953 825165 foxd3_1-2ss_peak_7 127 . 5.99576 18.9189 12.7976 95

```

FRiP


```


samtools view -c data/1-2ss/foxd3_1-2ss_chip.nuclear.bam
samtools view -c -L results/peaks/foxd3_1-2ss_peaks.narrowPeak data/1-2ss/foxd3_1-2ss_chip.nuclear.bam

```

reads всего: 12816614 | в пиках: 1799 | FRiP: 0.00014

Average profile и heatmap






Сравнение четырёх стадий

Сводка по всем стадиям - число пиков, FRiP и значимость сильнейшего пика:

Stage	ChIP_aln	Input_aln	Peaks	FRiP	maxQ
75ep	23863894	39931858	36	0.017%	100.05
1-2ss	12816614	33460348	40	0.014%	56.18
5-6ss	18853396	57051062	839	0.236%	163.70
14ss	41553880	27794668	170	0.162%	321.45

Число пиков проходит через максимум: 36 → 40 → 839 → 170. Foxd3 почти не садится на ДНК во время гастрюляции и ранней нейруляции, массово выходит на хроматин к спецификации (5-6ss) и затем оставляет лишь часть сайтов к миграции (14ss). FRiP повторяет ту же картину - сильнее всего на 5-6ss (0,24 %) и 14ss (0,16 %). Самый значимый отдельный пик - на 14ss ($-\log_{10}q = 321$).

Heatmap по стадиям



Pairwise overlap и Jaccard index

Попарные перекрытия и индекс Жаккара между всеми стадиями (bedtools intersect и bedtools jaccard на отсортированных наборах):

A	B	peaksA	peaksB	A_in_B	A_only	B_only	Jaccard
75ep	1-2ss	36	40	12	24	28	0.173709
75ep	5-6ss	36	839	22	14	817	0.0227149
75ep	14ss	36	170	18	18	152	0.0751444
1-2ss	5-6ss	40	839	30	10	809	0.0281266
1-2ss	14ss	40	170	12	28	158	0.0426345
5-6ss	14ss	839	170	40	799	130	0.0369399

- **75ep** - 75 % эпиволии (75 % epiboly) - поздняя гаструляция
- **1-2ss** - 1-2 сомита (1-2 somite stage) - ранняя нейруляция, начало сомитогенеза
- **5-6ss** - 5-6 сомитов (5-6 somite stage) - спецификация нервного гребня
- **14ss** - 14 сомитов (14 somite stage) - миграция нервного гребня

```
# для каждой пары A,B (наборы отсортированы sort -k1,1 -k2,2n):
bedtools intersect -a A.sorted.bed -b B.sorted.bed -u | wc -l # A n B
bedtools intersect -a A.sorted.bed -b B.sorted.bed -v | wc -l # только A
bedtools jaccard -a A.sorted.bed -b B.sorted.bed # Jaccard
```

Ближе всего 75ep и 1-2ss (Jaccard 0,17) - соседние ранние стадии; дальше всего 75ep и 5-6ss (0,02). 30 из 40 пиков 1-2ss и 22 из 36 пиков 75ep лежат внутри набора 5-6ss - ранние сайты в основном подмножество будущей программы. Между 5-6ss и 14ss Jaccard всего 0,04 при 839 и 170 пиках - репертуар сильно перекраивается.

Stage-specific peaks

Специфичные для стадии пики (bedtools intersect -v): у 14ss 130 из 170 пиков не пересекаются с 5-6ss, у 5-6ss 799 из 839 отсутствуют на 14ss. То есть большинство сайтов на каждом переходе меняется, а сохраняется лишь небольшое общее ядро (сильнейшие сайты).


```
bedtools intersect -a results/peaks/foxd3_14ss_peaks.narrowPeak -b teacher/foxd3_5-6ss_peaks.narrowPeak -v | wc -l
130

/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq [studfbmf01_29@calc.chipseq_seminar]$ bedtools intersect -a teacher/foxd3_5-6ss_peaks.narrowPeak -b results/peaks/foxd3_14ss_peaks.narrowPeak -v | wc -l
799
```


Визуализация в IGV

Три локуса (референс GRCz11 + GTF; дорожки по стадиям ChIP / Input / log₂; внизу вызванные пики).


1) Сильный пик 5-6ss - NC_007117.7:32 203 000-32 210 000. Сигнал ChIP на 5-6ss максимальный, log₂ > 0; пик есть на всех стадиях, но сильнее всего на 5-6ss.



2) Регион, общий для нескольких стадий - конститутивный сайт NC_007113.7 $\approx$ 33 276 000, пик на всех четырёх стадиях. При единой шкале ChIP 0–3 на 5-6ss сигнал упирается в потолок, на 14ss едва различим - присутствие пика не значит одинаковую силу связывания.



3) Stage-specific регион - NC_007112.7:256 000–264 000. Пик вызван только на 5-6ss; рядом ген (NM_001327759.1 / XM_005168005.5).



Форматы файлов

Коротко о форматах, которые фигурируют в задании:

- **GTF** (текст) - аннотация генов, транскриптов и экзонов с координатами; в IGV - дорожка генов.
- **BigWig (.bw)** (бинарный) - непрерывный сигнал (покрытие) в бинах; ChIP/Input в CPM и $\log_2(\text{ChIP/Input})$ для визуализации.
- **BED** (текст) - геномные интервалы chrom/start/end (+доп. поля); summits и результаты сравнения наборов.
- **narrowPeak** (текст) - BED6+4: пики MACS3 + signalValue, $-\log_{10}(\text{pValue})$, $-\log_{10}(\text{qValue})$, смещение вершины.
- **peaks.xls** (текст) - пики MACS3 с метаданными запуска (в шапке - total fragments для ChIP и Input, параметры).
- **matrix.gz** (бинарный, gz) - матрица deepTools: сигнал × позиция вокруг опорных точек; вход для plotHeatmap / plotProfile
- **FASTA** (текст) - референсная последовательность генома GRCz11; основа для выравнивания и референс-дорожка в IGV.
- **BAM** (бинарный) - выравнивания ридов на геном; вход всего пайплайна (flagstat, bamCoverage, MACS3 callpeak).

- **BAI** (бинарный) - индекс к BAM для быстрого доступа по координате (нужен bamCoverage и IGV).
- **TSV** (текст) - таблицы с разделителем-табуляцией (например frip.tsv: reads в пиках / всего).
- **PDF** (бинарный) - итоговые графики (profile, heatmap)

Биологический вывод

Как меняется геномный ландшафт связывания Foxd3 от гастрюляции к миграции нервного гребня и что можно считать биологическим различием, а что - эффектом качества ChIP-seq:

1. Связывание разворачивается к стадии спецификации: на 5-6ss больше всего пиков (839), самый высокий FRiP (0,24 %) и самый чистый профиль. К миграции (14ss) набор сокращается до 170, но остаются самые сильные сайты ($-\log_{10}q$ до 321).
2. Ранние стадии (75ep, 1-2ss) дают мало пиков (36–40), похожи между собой и почти целиком входят в программу 5-6ss.
3. Репертуар сайтов заметно перестраивается (низкие Jaccard между далёкими стадиями), но самые сильные сайты переживают переход спецификация - миграция.
4. Уверенно биологическое: рост числа пиков и обогащения к 5-6ss нельзя объяснить глубиной - там ChIP как раз самый мелкий (18,8 млн против 41,5 млн у 14ss). Направление динамики (мало - максимум на спецификации - обрезка к миграции) устойчиво.
5. Нельзя отделить от техники: абсолютные числа пиков и FRiP зависят от порога q , качества библиотек и глубины Input (у 5-6ss он самый большой). Поэтому сравнение велось единым пайплайном, а сами числа стоит считать ориентиром, а не точной величиной.
6. Наличие/отсутствие пика - это про порог детекции, а не «связывается / не связывается»: один сайт может присутствовать на нескольких стадиях с разной силой (см. второй локус IGV).
7. ChIP-seq показывает только, где Foxd3 садится на ДНК, но не говорит, включает он или выключает ближайший ген. Чтобы связать связывание с функцией, нужны дополнительные данные: доступность хроматина (ATAC-seq), метки активных энхансеров (ChIP-seq на H3K27ac) и экспрессия генов по стадиям (RNA-seq).