

Семинар по биоинформатике. ChIP-seq

Шилина Виктория

Посмотреть статистику ChIP BAM

```
cd ~/chipseq_seminar
samtools flagstat data/foxd3_14ss_chip.nuclear.bam
```

samtools flagstat даёт сводку по BAM: сколько всего выравниваний, сколько картировано, парных и «properly paired», сколько дубликатов и вторичных/дополнительных записей. Для ChIP получаем:

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf@...
chip.nuclear.bam
41553880 + 0 in total (QC-passed reads + QC-failed reads)
41553880 + 0 primary
0 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
41553880 + 0 mapped (100.00% : N/A)
41553880 + 0 primary mapped (100.00% : N/A)
41553880 + 0 paired in sequencing
20776940 + 0 read1
20776940 + 0 read2
41553880 + 0 properly paired (100.00% : N/A)
41553880 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
```

100 % ридов картированы и корректно спарены, дубликатов и secondary нет, значит BAM уже предпочищен. Тот же flagstat для Input даёт 27 794 668 выравниваний (13 897 334 пары), тоже без дубликатов. Главное отличие: ChIP примерно в 1,5 раза глубже Input, поэтому сравнивать их можно только как обогащение ChIP над Input после нормировки, а не по абсолютному числу ридов.

Постройте ChIP coverage

```
bamCoverage \
-b data/foxd3_14ss_chip.nuclear.bam \
-o results/signal/foxd3_14ss_chip.CPM.bw \
--normalizeUsing CPM --binSize 10 --numberOfProcessors 4
```

bamCoverage превращает BAM в непрерывный сигнал (BigWig): считает покрытие в окнах по 10 п.н. и нормирует его на глубину библиотеки (CPM). Флаги: -b - входной BAM, -o - выходной BigWig, --binSize 10 - окно 10 п.н., --normalizeUsing CPM - нормировка на глубину, --numberOfProcessors 4 - 4 ядра. Результат: results/signal/foxd3_14ss_chip.CPM.bw.

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq
signal/
total 1.9G
-rw-r--r-- 1 studfbmf01_29 fbmf 92M Sep 13 18:37 foxd3_1-2ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 182M Sep 13 18:40 foxd3_1-2ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 271M Sep 13 18:48 foxd3_1-2ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 211M Sep 25 11:35 foxd3_14ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 162M Sep 13 16:51 foxd3_14ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 350M Sep 13 17:01 foxd3_14ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 145M Sep 13 18:04 foxd3_75ep_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 203M Sep 13 18:07 foxd3_75ep_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 327M Sep 13 18:16 foxd3_75ep.log2_IP_Input.bw
```

Постройте Input coverage

Та же команда, но для контрольного BAM, получаем дорожку сигнала для Input:

```
bamCoverage \
-b data/foxd3_14ss_input.nuclear.bam \
-o results/signal/foxd3_14ss_input.CPM.bw \
--normalizeUsing CPM --binSize 10 --numberOfProcessors 4
```

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq
signal/
total 1.9G
-rw-r--r-- 1 studfbmf01_29 fbmf 92M Sep 13 18:37 foxd3_1-2ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 182M Sep 13 18:40 foxd3_1-2ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 271M Sep 13 18:48 foxd3_1-2ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 211M Sep 25 11:35 foxd3_14ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 162M Sep 13 16:51 foxd3_14ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 350M Sep 13 17:01 foxd3_14ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 145M Sep 13 18:04 foxd3_75ep_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 203M Sep 13 18:07 foxd3_75ep_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 327M Sep 13 18:16 foxd3_75ep.log2_IP_Input.bw
```

Рассчитайте enrichment ChIP относительно Input

```
bigwigCompare \
-b1 results/signal/foxd3_14ss_chip.CPM.bw \
-b2 results/signal/foxd3_14ss_input.CPM.bw \
--operation log2 --pseudocount 1 --binSize 10 \
-o results/signal/foxd3_14ss.log2_IP_Input.bw
```

Для каждого бина считается $S(x) = \log_2((\text{ChIP}(x)+1) / (\text{Input}(x)+1))$.

Псевдосчёт +1 нужен, чтобы не делить на ноль в пустых бинах. Если $S(x) > 0$ - сигнал ChIP выше Input (обогащение), если $S(x) < 0$, наоборот. Эта дорожка удобна тем, что фон уже вычтен.

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq
signal/
total 1.9G
-rw-r--r-- 1 studfbmf01_29 fbmf 92M Sep 13 18:37 foxd3_1-2ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 182M Sep 13 18:40 foxd3_1-2ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 271M Sep 13 18:48 foxd3_1-2ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 211M Sep 25 11:35 foxd3_14ss_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 162M Sep 13 16:51 foxd3_14ss_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 350M Sep 13 17:01 foxd3_14ss.log2_IP_Input.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 145M Sep 13 18:04 foxd3_75ep_chip.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 203M Sep 13 18:07 foxd3_75ep_input.CPM.bw
-rw-r--r-- 1 studfbmf01_29 fbmf 327M Sep 13 18:16 foxd3_75ep.log2_IP_Input.bw
```

Вызовите Foxd3 peaks

```
macs3 callpeak \
-t data/foxd3_14ss_chip.nuclear.bam \
-c data/foxd3_14ss_input.nuclear.bam \
-f BAMPE -g 1360000000 -n foxd3_14ss -q 0.01 \
```

```
--outdir results/peaks
```

MACS3 ищет участки генома, где сигнал ChIP статистически превышает ожидаемый фон (Input). Флаги: -t - ChIP (treatment), -c - Input (control), -f BAMPE - парные концы, -g - эффективный размер генома (~1,36·10⁹ для данио), -q 0.01 - порог по q-value (FDR), -n - имя анализа. Основной результат - results/peaks/foxd3_14ss_peaks.narrowPeak; дополнительно foxd3_14ss_summits.bed (вершины) и foxd3_14ss_peaks.xls (пики + метаданные запуска).

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 ~]$ ls -lh ~/chipseq_seminar/results/peaks
total 60K
-rw-r--r-- 1 studfbmf01_29 fbmf 3.2K Sep 13 18:53 foxd3_1-2ss_peaks.narrowPeak
-rw-r--r-- 1 studfbmf01_29 fbmf 4.8K Sep 13 18:53 foxd3_1-2ss_peaks.xls
-rw-r--r-- 1 studfbmf01_29 fbmf 2.3K Sep 13 18:53 foxd3_1-2ss_summits.bed
-rw-r--r-- 1 studfbmf01_29 fbmf 14K Sep 13 17:15 foxd3_14ss_peaks.narrowPeak
-rw-r--r-- 1 studfbmf01_29 fbmf 16K Sep 13 17:15 foxd3_14ss_peaks.xls
-rw-r--r-- 1 studfbmf01_29 fbmf 9.3K Sep 13 17:15 foxd3_14ss_summits.bed
-rw-r--r-- 1 studfbmf01_29 fbmf 2.9K Sep 13 18:22 foxd3_75ep_peaks.narrowPeak
-rw-r--r-- 1 studfbmf01_29 fbmf 4.4K Sep 13 18:22 foxd3_75ep_peaks.xls
-rw-r--r-- 1 studfbmf01_29 fbmf 2.0K Sep 13 18:22 foxd3_75ep_summits.bed
```

Сколько найдено peaks?

```
wc -l results/peaks/foxd3_14ss_peaks.narrowPeak
# 170
```

Найдено 170 пиков. Можно ли считать это числом сайтов связывания Foxd3? Напрямую - нет. Пик - это область, где обогащение прошло порог $q < 0,01$ при данной глубине и качестве эксперимента. Часть реальных сайтов даёт слабый сигнал и не проходит порог, а иногда близкие сайты сливаются в один пик. Так что число пиков - это оценка снизу и приближение, а не точный счёт сайтов.

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq_seminar]$ wc -l results/peaks
ks.narrowPeak
170 results/peaks/foxd3_14ss_peaks.narrowPeak
```

Посмотрите структуру narrowPeak

```
head results/peaks/foxd3_14ss_peaks.narrowPeak
```

Формат narrowPeak - BED6+4, десять колонок:

- 1) chrom - хромосома; 2) start - начало пика (0-based); 3) end - конец;
- 4) name - имя пика (foxd3_14ss_peak_N); 5) score - целочисленный score для отображения; 6) strand - цепь (. если не определена);
- 7) signalValue - кратность обогащения (fold enrichment); 8) $-\log_{10}(\text{pValue})$; 9) $-\log_{10}(\text{qValue})$; 10) peak - смещение вершины (summit) от start.

Пример строк:

```
(/home/STUDY/FBMF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq_seminar]$ head results/peaks
s.narrowPeak
NC_007112.7 844066 844303 foxd3_14ss_peak_1 112 . 5.45518 16.2363 11.2721 158
NC_007112.7 2888865 2889138 foxd3_14ss_peak_2 27 . 3.79941 7.02904 2.70006 24
NC_007112.7 38224481 38224863 foxd3_14ss_peak_3 296 . 7.43349 35.4518 29.6614 84
NC_007112.7 52006311 52006785 foxd3_14ss_peak_4 1523 . 17.8532 159.07 152.393 213
NC_007113.7 814715 814992 foxd3_14ss_peak_5 344 . 7.09107 40.3825 34.4909 157
NC_007113.7 14005869 14006106 foxd3_14ss_peak_6 335 . 7.68882 39.428 33.5531 115
NC_007113.7 14675566 14675887 foxd3_14ss_peak_7 91 . 2.62112 14.0218 9.17759 263
NC_007113.7 33276096 33276465 foxd3_14ss_peak_8 285 . 5.53431 34.3082 28.5409 152
NC_007114.7 14914162 14914708 foxd3_14ss_peak_9 2804 . 34.6699 287.998 280.494 304
NC_007115.7 17823384 17823661 foxd3_14ss_peak_10 291 . 8.16605 34.8852 29.1046 168
```

Найдите наиболее значимые peaks

```
sort -k9,9nr results/peaks/foxd3_14ss_peaks.narrowPeak | head
```

Сортируем по 9-й колонке - это $-\log_{10}(q\text{Value})$, то есть значимость; -k9,9nr даёт убывание, самые значимые сверху. Самый значимый пик - peak_74 с $-\log_{10}(q) = 321,45$. Отсюда q-value самого значимого пика = $10^{-321,45} \approx 3,5 \cdot 10^{-322}$ - практически ноль.

```
(/home/STUDY/FBMBF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq_seminar]$ sort -k9,9nr 4ss_peaks.narrowPeak | head
NC_007126.7 35583506 35583991 foxd3_14ss_peak_74 3214 . 24.9995 330.35 321.453 230
NC_007114.7 14914162 14914708 foxd3_14ss_peak_9 2804 . 34.6699 287.998 280.494 304
NC_007112.7 52006311 52006785 foxd3_14ss_peak_4 1523 . 17.8532 159.07 152.393 213
NW_003336809.1 1264 1906 foxd3_14ss_peak_149 1480 . 2.99794 154.712 148.07 206
NW_003336809.1 684 949 foxd3_14ss_peak_148 1152 . 3.34538 121.64 115.225 201
NC_007129.7 46370033 46370416 foxd3_14ss_peak_96 935 . 15.2699 99.8794 93.5617 153
NW_003336678.1 17930 18156 foxd3_14ss_peak_140 801 . 3.8773 86.3815 80.1415 43
NC_007129.7 44275947 44276326 foxd3_14ss_peak_95 586 . 12.9962 64.7909 58.6621 196
NC_007115.7 24985710 24985968 foxd3_14ss_peak_11 451 . 8.89114 51.1718 45.1445 121
NC_007134.7 35840142 35840449 foxd3_14ss_peak_108 431 . 8.67428 49.1783 43.1735 175
```

Сколько reads всего в ChIP?

```
samtools view -c data/foxd3_14ss_chip.nuclear.bam
```

Получаем число выравниваний в ChIP BAM - 41 553 880. Это знаменатель для FRiP.

```
(/home/STUDY/FBMBF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq_seminar]$ samtools view -c data/foxd3_14ss_chip.nuclear.bam
41553880
```

Сколько reads попало в peaks?

```
samtools view -c \
-L results/peaks/foxd3_14ss_peaks.narrowPeak \
data/foxd3_14ss_chip.nuclear.bam
```

Флаг -L ограничивает подсчёт интервалами из narrowPeak, то есть считаются только выравнивания внутри вызванных пиков - 67 346. Это числитель для FRiP.

```
(/home/STUDY/FBMBF/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@node210-19 chipseq_seminar]$ samtools view -c \
-L results/peaks/foxd3_14ss_peaks.narrowPeak \
data/foxd3_14ss_chip.nuclear.bam
67346
```

Рассчитайте FRiP

FRiP (fraction of reads in peaks) = риды в пиках / все риды ChIP:

```
FRiP = 67346 / 41553880 = 0.00162 (0.16 %)
```

Значение низкое, но это ожидаемо: 170 узких пиков на геном ~1,4 млрд п.н. физически не могут собрать большую долю такой глубокой библиотеки, остальное - фон. Поэтому FRiP имеет смысл сравнивать между стадиями, а не оценивать по одному числу.


Соберите signal вокруг summit

```
computeMatrix reference-point \
--referencePoint center \
-R results/peaks/foxd3_14ss_summits.bed \
-S results/signal/foxd3_14ss_chip.CPM.bw \
results/signal/foxd3_14ss_input.CPM.bw \
-b 2000 -a 2000 --binSize 20 \
-o results/figures/foxd3_14ss.matrix.gz
```

Результат - матрица: строки соответствуют пикам (вершина ± 2 кб), столбцы - бинам по 20 п.н., значения - сигнал в каждой точке, отдельно для ChIP и для Input. Эта матрица дальше идёт на heatmap и профиль.

Постройте heatmap

```
plotHeatmap \  
-m results/figures/foxd3_14ss.matrix.gz \  
-out results/figures/foxd3_14ss.heatmap.pdf \  
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```



Постройте average profile

```
plotProfile \  
-m results/figures/foxd3_14ss.matrix.gz \  
-out results/figures/foxd3_14ss.profile.pdf \  
--samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```




График показывает средний сигнал по всем пикам вокруг вершины. У ChIP - острый центральный пик, у Input сигнал заметно ниже (хотя и с небольшим центральным бугром - это фоновая структура хроматина). Такой контраст и означает специфическое связывание Foxd3 в этих точках.

Найдите peaks, общие для 5-6ss и 14ss

```
bedtools intersect \
-a teacher/foxd3_5-6ss_peaks.narrowPeak \
-b results/peaks/foxd3_14ss_peaks.narrowPeak \
-u > results/stage_comparison/shared_5-6ss_14ss.bed
```

bedtools intersect ищет пересечения геномных интервалов: -a - пики 5-6ss, -b - пики 14ss, -u - каждый пик из A выводится максимум один раз. Получаем пики 5-6ss, у которых есть хотя бы одно пересечение с 14ss.

Сколько peaks сохраняется на 14ss?

```
wc -l results/stage_comparison/shared_5-6ss_14ss.bed
```

Общих пиков - 40. Для сравнения: всего у 5-6ss 839 пиков, у 14ss 170, общих 40. То есть к стадии миграции удерживается лишь небольшая часть программы спецификации.

```
(/home/STUDY/FBMB/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@calc chipseq]$ bedtools intersect -a results/peaks/foxd3_14ss_peaks.narrowPeak \
-b teacher/foxd3_5-6ss_peaks.narrowPeak -u \
> results/stage_comparison/shared_5-6ss_14ss.bed
wc -l results/stage_comparison/shared_5-6ss_14ss.bed
40 results/stage_comparison/shared_5-6ss_14ss.bed
```

Найдите специфичные для 14ss peaks

```
bedtools intersect \
-a results/peaks/foxd3_14ss_peaks.narrowPeak \
-b teacher/foxd3_5-6ss_peaks.narrowPeak \
-v > results/stage_comparison/only_14ss.bed
```

Флаг -v оставляет интервалы из A, которые не пересекаются ни с одним интервалом из B. Таких пиков 130 - они специфичны для 14ss (40 общих + 130 своих = 170, всё верно).

```
(/home/STUDY/FBMB/bioinformatics/chipseq/software/seminar1-chipseq) [studfbmf01_29@calc chipseq_seminar]$ bedtools intersect -a results/peaks/foxd3_14ss_peaks.narrowPeak \
-b teacher/foxd3_5-6ss_peaks.narrowPeak -v \
> results/stage_comparison/only_14ss.bed
wc -l results/stage_comparison/only_14ss.bed
130 results/stage_comparison/only_14ss.bed
```

Итоговая структура результатов

По итогу семинара структура результатов для 14ss повторяет то, что было для 5–6ss:

```
results/
├── signal/
│   ├── foxd3_14ss_chip.CPM.bw
│   ├── foxd3_14ss_input.CPM.bw
│   └── foxd3_14ss.log2_IP_Input.bw
├── peaks/
│   ├── foxd3_14ss_peaks.narrowPeak
│   ├── foxd3_14ss_summits.bed
│   └── foxd3_14ss_peaks.xls
├── figures/
│   ├── foxd3_14ss.matrix.gz
│   ├── foxd3_14ss.heatmap.pdf
│   └── foxd3_14ss.profile.pdf
└── stage_comparison/
    ├── shared_5-6ss_14ss.bed
    └── only_14ss.bed
```

```
results
+-- figures
|   +-- foxd3_1-2ss.heatmap.pdf
|   +-- foxd3_1-2ss.matrix.gz
|   +-- foxd3_1-2ss.profile.pdf
|   +-- foxd3_14ss.heatmap.pdf
|   +-- foxd3_14ss.matrix.gz
|   +-- foxd3_14ss.profile.pdf
|   +-- foxd3_75ep.heatmap.pdf
|   +-- foxd3_75ep.matrix.gz
|   +-- foxd3_75ep.profile.pdf
+-- peaks
|   +-- foxd3_1-2ss_peaks.narrowPeak
|   +-- foxd3_1-2ss_peaks.xls
|   +-- foxd3_1-2ss_summits.bed
|   +-- foxd3_14ss_peaks.narrowPeak
|   +-- foxd3_14ss_peaks.xls
|   +-- foxd3_14ss_summits.bed
|   +-- foxd3_75ep_peaks.narrowPeak
|   +-- foxd3_75ep_peaks.xls
|   +-- foxd3_75ep_summits.bed
+-- qc
|   +-- 14ss_chip.flagstat.txt
|   +-- 14ss_input.flagstat.txt
|   +-- frip_1-2ss.tsv
|   +-- frip_14ss.tsv
|   +-- frip_75ep.tsv
+-- signal
|   +-- foxd3_1-2ss_chip.CPM.bw
|   +-- foxd3_1-2ss_input.CPM.bw
|   +-- foxd3_1-2ss.log2_IP_Input.bw
|   +-- foxd3_14ss_chip.CPM.bw
|   +-- foxd3_14ss_input.CPM.bw
|   +-- foxd3_14ss.log2_IP_Input.bw
|   +-- foxd3_75ep_chip.CPM.bw
|   +-- foxd3_75ep_input.CPM.bw
|   +-- foxd3_75ep.log2_IP_Input.bw
+-- stage_comparison
|   +-- only_14ss.bed
|   +-- shared_5-6ss_14ss.bed
+-- sorted
|   +-- 1-2ss.sorted.bed
|   +-- 14ss.sorted.bed
|   +-- 5-6ss.sorted.bed
|   +-- 75ep.sorted.bed
```